

Zürich Tram Flow

Was 93.9 Millionen Verspätungsdatenpunkte über das Zürcher Tramnetz verraten — und warum das Problem lösbar ist.

~85M

DATENPUNKTE (LF_CLEAN)

63

ANALYSEBEFUNDE

–63%

MAE VS. BASELINE

18.6s

MAE LIGHTGBM V2

„Die Verspätungen im Zürcher Tramnetz sind vorhersagbar — weil sie im Fahrplan-Design verankert sind, nicht im zufälligen Betrieb. Was vorhersagbar ist, ist steuerbar.“

Verspätungs-Hotspots im Zürcher Tramnetz

Abb. 1 — Ø Verspätung je Haltestelle 2023–2025. Periphere Aussenkorridore dominieren, nicht zentrale Knotenpunkte.

DAS PROBLEM

OTP 87% — und warum das Netz nicht besser wird

VBZ-Ziel: 95% OTP ($\text{arrival_delay} \leq 120\text{s}$). Ist: 87%. Die Lücke von 8 Prozentpunkten ist nicht zufällig — sie ist systematisch erzeugt.

87%

OTP (IST)

95%

OTP (VBZ-ZIEL)

71.5%

HALTE
AKKUMULIEREN
DELAY

71.3%

DWELL_TIME = 0s

An 71.5% aller Halte akkumuliert die Tram Verspätung ($\text{delay_delta} > 0$) — und 71.3% aller Haltestellen haben 0s Standzeit eingebaut. Kein Puffer bedeutet: ist die Tram einmal verspätet, kann sie sich nicht erholen. Das ist keine Wetter- und kein Event-Problem. Es ist ein Fahrplan-Design-Problem.

OTP aller Linien

OTP nach Linie — L11 (82%) und L8 weit unter Ziel

Delay Delta aller Linien

Delay Delta — alle Linien akkumulieren positiv

BEWEISKETTE

4 Schritte vom Befund zur Erklärung

Die These ist nicht behauptet, sondern bewiesen — mit vier aufeinanderfolgenden Analysen, die voneinander unabhängig auf dasselbe Muster zeigen.

SCHRITT 1 — ANOMALIE

Hotspots an der Peripherie

Friedhof Enzenbühl (93.8s), Balgrist (85.2s), Leutschenbach (82.7s) — nicht Central oder Paradeplatz. 0 Overlap zwischen Liniendichte und Delay.

0 Overlap Top-Dichte × Top-Delay

SCHRITT 2 — GRADIENT

Delay wächst entlang der Strecke

L11 zeigt wachsende Bubbles von Innenstadt zur Peripherie. L6 (beste Linie) bleibt gleichmässig. Das Muster ist linienspezifisch, nicht haltespezifisch.

L11 68.7s · L6 best performer

SCHRITT 3 — MECHANISMUS

Kein Puffer — keine Erholung

71.3% aller Haltestellen haben dwell_time = 0s. Die röttesten Stops (höchster Delay) sind gleichzeitig die grössten (höchster %-Anteil ohne Puffer). Smoking Gun.

71.3% dwell_time = 0s

SCHRITT 4 — KASKADE

Pearson $r \geq 0.85$ auf allen 16 Linien

Der Delay an Halt n korreliert mit $r \geq 0.85$ mit dem Delay an Halt n+1 — netzweit. Kein statistisches Artefakt: das Modell lernt dieses Signal direkt.

$r \geq 0.85$ · alle 16 Linien

Dwell-Time-Profil

Dwell-Time-Profil aller Linien — dominiert von 0s-Werten

Delay + Dwell kombiniert

Linie: Delay (Balken) + Dwell-Anteil — strukturelle Kopplung

ANALYSEBEFUNDE

63 Findings — 6 davon entscheiden

Sechs Analyse-Notebooks · 3 Jahre Daten · 16 Tramlinien · Zürich. Hier die stärksten Findings pro Dimension.

SPATIAL

Hotspots an der Peripherie

Friedhof Enzenbühl (93.8s), Balgrist (85.2s), Leutschenbach (82.7s). Central und Paradeplatz liegen unter Netzschnitt. Kreis 11 schlechtester Stadtkreis (68.3s, OTP 83%).

0 Overlap

03_analysis_4-spatial.ipynb · F-SPAT-01/03/07

TEMPORAL

Kein Morgenrush — Peak um 21h

7h liegt mit 48.9s unter dem Netzschnitt. Der echte Peak ist 21h (67.9s) durch Events-Abreisewellen. Donnerstag kritischster Wochentag (60.4s, P95=194s). November jeweils Jahreshöchstwert (72.6s in 2024).

+11.7s um 21h

03_analysis_3-temporal.ipynb · F-TEMP-01/02/05

STRUKTUR

Kein Puffer eingebaut

71.5% aller Halte akkumulieren Delay ($\text{delay_delta} > 0$). 71.3% aller Haltestellen haben 0s dwell_time . Das System hat keinen Erholungsmechanismus eingebaut — Verspätung ist das Default.

71.3% $\text{dwell_time} = 0\text{s}$

03_analysis_1-target.ipynb · 03_analysis_4-spatial.ipynb

METEO

Schnee geografisch trennbar von Regen

Schnee stärkster Einzeleffekt (+54s, OTP −10.9pp). Geografisch klar getrennt: Schnee trifft Höhenlagen (K10/K4/K12), Regen trifft Flusstäler (K5). L9: Schnee +75.9s vs. Regen +10.0s — L17 umgekehrt.

Schnee +54s · Regen +23.3s

03_analysis_5-meteo.ipynb · F-WEAT-01/07/09

EVENTS

Feiertage beste Tage · Fachmessen schlechteste

Feiertage 46.3s (−9.9s vs. Normal) — MIV-Rückgang überwiegt jeden Event-Effekt. Event-Wirkung ist ein Abend-Phänomen (18–22h): tagsüber kein Unterschied. Fachmessen (66.0s) schlagen Taylor Swift (75.4s).

Feiertage −9.9s

03_analysis_6-events.ipynb · F-EVNT-01/03/04

KASKADE

Pearson $r \geq 0.85$ auf allen 16 Linien

Der Delay an einem Halt überträgt sich mit $r \geq 0.85$ auf den Folgehalt desselben Trips — netzweit auf allen 16 Linien. Das ist kein Artefakt: LightGBM v2 lernt genau dieses Signal und senkt MAE von 45.7s auf 18.6s.

$r \geq 0.85$ (alle 16 Linien)

03_analysis_4-spatial.ipynb · 06_prediction_4-model_v2.ipynb

Spatial

OTP nach Stadtkreis

OTP nach Stadtkreis — K11/K12 als Priority Zones

Delay nach Stadtkreis + Stops

Ø Delay: Stadtkreise + Haltestellen kombiniert

Temporal

Delay nach Stunde

Ø Delay nach Stunde — Peak 21h, nicht 8h

Delay nach Wochentag

Ø Delay nach Wochentag — Donnerstag kritisch

Delay nach Saison

Ø Delay nach Saison — Winter überraschend beste Jahreszeit

Meteo

Wettertypen-Vergleich

Wettertypen: Normal / Regen / Schnee im Vergleich

Schnee-Effekt nach Stadtkreis

Schnee-Effekt nach Stadtkreis — Höhenlagen betroffen

Starkregen-Effekt

Starkregen-Effekt — Fluss-Korridor K5

Events

Event-Timeline

Event-Timeline 2023–2025 mit Kategorien

Event-Kategorien Delay-Vergleich

Event-Kategorien — Fachmessen schlechteste Kategorie

DATA SCIENCE

Modellentwicklung — vom Baseline zum Real-Time Signal

Drei Schritte: Baseline-Benchmark → LightGBM v1 (Schedule + Weather + Events) → LightGBM v2 (+Kaskadenindikator). Der Sprung von v1 auf v2 ist kein Hyperparameter-Tuning — es ist Feature Engineering, das die Analyse bestätigt.

Baseline Benchmark

Modell	Logik	Test MAE
Grand Mean	Immer $\emptyset$ Netzschnitt vorhersagen	50.6s
Hour Mean	$\emptyset$ nach Tagesstunde	50.5s
Line Mean	$\emptyset$ nach Linie	50.4s
Stop Mean	$\emptyset$ nach Haltestelle ← Benchmark	50.0s

Modellprogression

Modell	Features	Test MAE	vs. Baseline	Datenbedarf
Stop Mean	—	50.0s	—	Historischer Stop-Ø
LightGBM v1	34 (Zeit · Wetter · Events · Stop · Linie)	45.7s	−4.3s	Fahrplan + Wetter + Events
LightGBM v2	36 (+prev_trip_delay, +stop_sequence_pct)	18.6s	−31.4s (−63%)	+ Live-Signal (Vorgänger-Halt)



Robustheits-Check: XGBoost auf gleichem Feature-Set → val MAE ~21.4s (150 Runden, Abbruch nach >90 Min auf 85M Zeilen) — 5× langsamere Trainingszeit. Das Signal steckt in den Daten, nicht im Algorithmus. LightGBM klar überlegen.

Was das Modell bestätigt

prev_trip_delay ist das wichtigste neue Feature in v2 — der direkte Kaskadenindikator aus der Analyse (Pearson $r \geq 0.85$). Die Feature Importance bestätigt: das Modell hat dieselbe Struktur gelernt wie die 63 Findings der Analyse-Phase. Analyse und Modell zeigen auf dasselbe Muster.

LightGBM v1 (Pre-Trip-Modell) arbeitet nur mit Fahrplan, Wetter und Events — nutzbar für Disposition am Vortag. LightGBM v2 (In-Trip-Signal) braucht den Vorgänger-Halt als Input — nutzbar für Real-Time Dispatch während des Betriebs.

Live-Szenario

Input	Wert
Wochentag · Uhrzeit	Dienstag · 17:00
Haltestelle	Paradeplatz
Linie	11
Wetter	Leichter Regen
Vorhergesagter Delay	~52s

EMPFEHLUNGEN

4 Handlungsfelder — alle durch Daten gedeckt

Jede Empfehlung ist direkt auf einen Analysebefund zurückführbar. Keine unbegründeten Claims.

HEBEL #1

Fahrplan-Redesign L11 — gezielter Puffer einbauen

71.3% aller Haltestellen haben 0s dwell_time — kein Erholungsmechanismus. L11 (68.7s, OTP 82%) und ihre Endstationen zeigen die stärkste Akkumulation. Selbst +10s Puffer an 3–5 kritischen Koppelstellen würde den Kaskadeneffekt unterbrechen. (Basis: F-SPAT-08 · Pearson $r \geq 0.85$)

MODELL

Real-Time Dispatch — Kaskadenmodell operativ nutzen

LightGBM v2 erreicht MAE 18.6s (–63% vs. Baseline) mit prev_trip_delay als Live-Signal. Das Signal ist echtzeit-verfügbar (Vorgänger-Halt als Input). Ein Dispatchsystem könnte automatisch Taktlücken schliessen bevor der Kaskadeneffekt entsteht.

BETRIEB

Kapazitätsmanagement 20–22h — Event-Abreisewelle abfedern

Peak ist 21h (+11.7s vs. Netzschnitt) durch Abreisewellen nach Events. Donnerstag und Freitag mit Grossevents ist die kritischste Kombination. Takterhöhung 20–22h auf L11/L8 wäre durch Daten direkt begründbar. (Basis: F-TEMP-01 · F-EVNT-03)

MONITORING

OTP-Monitoring nach Stadtkreis — K11/K12 als Priority Zones

Kreis 11 (68.3s, OTP 83%) und Kreis 12 (66.3s) sind strukturell benachteiligt. Automatisiertes Alert-System auf Haltestellenebene — kombiniert mit dem Prediction-Modell als Frühwarnsignal — ermöglicht proaktive Steuerung statt reaktiver Entstörung.

DER VOLLSTÄNDIGE KREIS

Vorhersagbar heisst: steuerbar

Das Projekt endet nicht mit dem Modell — es endet mit einer Handlungsgrundlage. Delays sind strukturell, nicht zufällig. Was Muster hat, kann man designen.

① ANALYSE

63 strukturierte Findings

71.5% aller Halte akkumulieren Delay. 71.3% ohne Puffer. Hotspots an der Peripherie — nicht an Knotenpunkten.

F-SPAT-08 · F-TARGET-03

② KERNEBUND

Delays sind intrinsisch

dwel_time = Feature #1. Kaskadeneffekt $r = 0.85$. Das System kann Verspätung nicht abbauen — kein Puffer eingebaut.

F-SIM-01 · F-SIM-02

③ MODELL

MAE 18.56s beweist Muster

Zufällige Delays sind nicht so präzise vorhersagbar. Vorhersagbarkeit ist der Beweis für Strukturalität.

–63% vs. Baseline

④ EMPFEHLUNG

Modell informiert Fahrplan

Risiko-Matrix: Stop × Linie × Kontext. WO und WANN Puffer fehlen — Grundlage für stopspezifische dwel_time-Kalibrierung.

F-REC-01 · F-REC-02

*Das Modell liefert die **Diagnose** (WO und WANN das Risiko hoch ist) — der Betrieb liefert die **Dosis** (wie viel Puffer pro Stop). Validierung durch gezieltes A/B-Testing: Stops mit angepasster dwel_time → Δ Delay messen → kalibrieren.*

Fahrplan-Puffer-Empfehlungen — interaktive Karte

Alle Haltestellen mit Puffer-Bedarf nach Betriebskontext (Normal · Schnee · Event · Rush · Spätnacht). Farbe = Kontext · Größe = empfohlener Puffer. Traces über die Legende ein-/ausblendbar.

PROJEKT-ÜBERSICHT

Stack · Daten · Architektur

Tech Stack

Bereich	Tools
Data Engineering	Polars · Parquet · GTFS · Open-Meteo
EDA & Analyse	Polars LazyFrame · Pandas · wgnd.inspect
Visualisierung	Plotly Mapbox · Matplotlib · Seaborn
Modellierung	LightGBM · scikit-learn · Isotonic Regression
Notebooks	Jupyter · nbconvert · uv

Datenbasis

Kennzahl	Wert
Rohdaten total	93.9M Zeilen
If_clean (Modell)	~85M Zeilen
Train-Set	41.2M Zeilen
Test-Set	~29M Zeilen
Zeitraum	2023–2025
Linien	16 Tramlinien
Quellen	VBZ IST + GTFS + Meteo + Events

Bekannte Limitierungen

Limitierung	Konsequenz
LightGBM v2 braucht prev_trip_delay als Live-Signal (In-Trip-Kontext)	Für Pre-Trip-Vorhersage ist v1 der richtige Ansatz
stop_name als native Categorical statt Target Encoding	BACKLOG #16 — Verbesserungspotenzial in v3
GTFS-Artefakt Nov/Dez 2025 (j25→j26 Fahrplanwechsel)	departure_delay/delay_delta maskiert — arrival_delay unberührt
XGBoost: >90 Min Training auf 85M Zeilen (CPU)	Robustheits-Check mit 150 Runden — LightGBM klar überlegen