

Zürich Tram Flow

Technischer Deep Dive · Data Engineering · EDA · Feature Engineering · LightGBM

Kay Wiegand · 2023–2025

94.4M

Halt-Ereignisse aus 4
Datenquellen

50.0s

Baseline MAE (Stop Mean)

18.6s

LightGBM v2 MAE (Test 2025)

–63%

Verbesserung vs. Baseline

AUSGANGSSITUATION

OTP-Lücke und strukturelles Defizit

Ziel: `arrival_delay` in Sekunden vorhersagen — direkt kommunizierbar, kein Schwellwert-Bias. Temporaler Split (kein Shuffle): Train 2023–Jun 2024 / Val Jul–Dez 2024 / Test 2025.

87%

OTP netzweit

Pünktlichkeitsrate 2023–2025

–8 PP

Lücke zum Ziel

VBZ-Ziel 95% bis 2028

56.3s

Ø Ankunftsverspätung

Netzweit über alle Halte

71.5%

Halte akkumulieren Delay

Strukturelles Verspätungsmuster

Datenstrategie

Vier Quellen, ein temporaler Join, 94.4 Millionen Zeilen



01

VBZ IST-Daten (Primärquelle)

- Reale Ankunfts- und Abfahrtszeiten aller Tramhalte 2023–2025
- Granularität: Fahrt × Haltestelle × Timestamp
- Canceled-Fahrten bewusst behalten (relevante Extremfälle)

03

Meteo Schweiz

- Stündliche Messwerte: Temperatur, Niederschlag, Wind
- Join über Zeitstempel (hour-level) auf IST-Daten
- Flags: has_rain, has_snow, has_heavy_rain, is_hot

02

GTFS (Fahrplandaten)

- Geplante Ankunfts-/Abfahrtszeiten, dwell_time, stop_sequence
- Liniengeometrien und Haltestellen-Koordinaten (lat/lon)
- Join-Key: trip_id × stop_id × service_date

04

Event-Kalender

- Grossveranstaltungen Zürich 2023–2025: Konzerte, Messen, Sport
- Kategorisierung: event_type, event_size, event_weight
- Ergebnis: 94.4 Mio. Zeilen · 26 Features · 541 MB Parquet

Baseline

Stop Mean als sinnvollster naiver Benchmark — jedes Modell muss diesen schlagen



Stop Mean gewinnt

Haltestellen haben strukturell unterschiedliche Delay-Level — der Halt selbst ist das stärkste naive Signal.



Grand / Hour / Line Mean

Alle alternativen Mittelwert-Strategien liegen $< 1s$ voneinander entfernt — kein messbarer Vorteil.



MAE 50.0s als Hürde

Der Stop Mean MAE von 50.0s ist der klare, direkt kommunizierbare Benchmark für alle Modellversionen.

34 Features v1 · 36 Features v2 — der entscheidende Unterschied

Temporale Features (v1)

hour, weekday, month, season, year · is_weekend,
is_november, is_holiday · is_late_night_weekend

Externe Features (v1)

temperature, precipitation, wind_speed · has_rain,
has_heavy_rain, has_snow · has_event, event_type,
event_size, event_weight



Netz-Features (v1)

line_name, stop_name (native categoricals) · district_nr,
n_lines_at_stop · is_start_stop, is_end_stop, dwell_time


Kaskaden-Features (neu in v2)

prev_trip_delay: Verspätung des Vorgänger-Trips —
echtzeit-verfügbar · stop_sequence_pct: normierter
Streckenfortschritt (0–1) · MAE 45.7s → 18.6s, -63%

Modellauswahl und Anpassung

Der MAE-Sprung von 45.7s auf 18.6s erklärt sich vollständig durch `prev_trip_delay` — das Signal steckt in den Daten, nicht im Algorithmus.

④ v1 war systematisch zu optimistisch (MBE +8.3s). v2 mit Isotonic-Regression-Kalibrierung: MBE -0.69s.



LightGBM v2 Test MAE
Finales Modell, Test-Set 2025



LightGBM Trainingszeit
Auf 85M Zeilen — iterativ einsetzbar



XGBoost Val MAE
Vergleichbare Qualität, 5× mehr Zeit (90+ Min)

☐ LightGBM ist die klar überlegene Wahl für iteratives Feature Engineering — das ist eine Workflow-Entscheidung, keine Qualitätskompromittierung.

Feature Importance & Produktionsreife

prev_trip_delay dominiert — die Kaskadenanalyse ($r \geq 0.85$ netzweit) hat die Feature-Wichtigkeit korrekt antizipiert. Das Modell bestätigt: das Signal steckt in den Daten.

Feature Importance

prev_trip_delay dominiert das Modell.
stop_sequence_pct generalisiert
linienübergreifend. Temporale und Netz-
Features ergänzen konsistent.

Offen bleibt

Online-Learning für Drift. Fahrgastzahlen als
zusätzliches Signal. Deployment-
Infrastruktur und Monitoring-Pipeline.

1

2

3

4

Produktionsreif

Temporal Split ohne Leakage. Isotonic-
Kalibrierung reduziert systematischen Bias.
prev_trip_delay ist echtzeit-verfügbar am
Betriebshalt.

Handlungsempfehlungen

Vier Empfehlungen, jede direkt durch Modell
oder Analyse gedeckt — fokussiert auf VBZ-
Ziel 95% bis 2028.

Zürich Tram Flow

Kay Wiegand · 2023–2025

End-to-End ML-Projekt zur Vorhersage von Tramverspätungen im Zürcher Netz. GitHub:
[kaywiegand/zh-tram-flow](https://github.com/kaywiegand/zh-tram-flow)

94.4M

Halt-Ereignisse

41.2M

Trainings-Fahrten

36

Features (v2)

18.6s

MAE · LightGBM v2

–63%

vs. Baseline

[GitHub ansehen](#)

[Fragen & Diskussion](#)

Made with GAMMA

