

ZÜRICH TRAM FLOW

EINE DATENGETRIEBENE REISE ZUR WURZEL DER VERSPÄTUNG.

TERMINAL

DATENBASIS:
94.4 MILLIONEN EVENTS
(2023-2025)



TERMINAL

SCOPE:
16 TRAMLINIEN,
VOLLSTÄNDIGES VBZ-NETZ




TERMINAL


ZIEL-METRIK:
ON-TIME PERFORMANCE (OTP) &
VORHERSAGEGENAUIGKEIT (MAE)



Die Mission: Wo sind die fehlenden 8 Prozent?



Zürichs Tramnetz liegt im europäischen Spitzenfeld. Doch 13% aller Ankünfte verfehlen das Pünktlichkeitsziel (Arrival Delay > 120s). Um diese Lücke zu schliessen, suchen wir in 94.4 Millionen Datenpunkten nach strukturellen Mustern.




Der erste Rückschlag: Wenn Daten die Realität verzerren

⚠ Phantom-Ausfälle (Vor Juli 2024)



Befund: Eine Änderung der Datendefinition beim Anbieter liess Kurzwendungen als Vollaussfälle erscheinen.

⊗ Das Zukunfts-Artefakt (Nov/Dez 2025)



Befund: Vorbereitungen für das Tramnetz Süd (GTFS-Update j26) ruinierten die Soll-Ist-Abgleiche im System.


✅ Die If_clean Strategie

Bereinigt auf ~85 Millionen verifizierte Zeilen.


Erkenntnis: Bevor ein Algorithmus Muster erkennen kann, muss die Domänenlogik die Daten von System-Artefakten befreien.

Zeitliche Mythen: Wo bleibt die Morgen-Rushhour?

Erwartung



Realität



- Kein Morgenrush: 07:00 Uhr liegt mit 48.9s unter dem Netzschnitt. Pendler sind pünktlich.
- > Der wahre Peak: 21:00 Uhr (67.9s) – Die Abreisewelle nach Gross-Events und Feierabend.
 - > Der schlimmste Tag: Donnerstag (60.4s), nicht Freitag.
 - > Die beste Zeit: Winter (51.7s) schlägt den Sommer, weil der MIV abnimmt.

Räumliche Mythen: Das Zentrum ist unschuldig

~85M

DATENPUNKTE (LF_CLEAN)

63

ANALYSEBEFUNDE

-63%

MAE VS. BASELINE

18.6s

MAE LIGHTGBM V2

Zentrale Knotenpunkte



Haldenegg / Paradeplatz
14-15 Linienkreuzungen
Delay: ~45-48s (Unter Netzschnitt)

Aussenkorridore (Peripherie)

Friedhof Enzenbühl / Balgrist
Periphere Endstationen
Delay: 85-93s (Kritische Hotspots)




Dichte ist kein Verspätungstreiber. Die Hotspots liegen in den Aussenkreisen. Der Netzausbau 2023 zielte auf gut performende Kreise — die Problemzonen erhielten keine neuen Haltestellen.

Wetter & Events: Die Topografie der Störung

1. Schnee (+54.0s)

● Alert Orange



Schnee betrifft primär die Höhenlagen (Kreise 10, 4, 12). Massive OTP-Reduktion.

2. Starkregen (+23.3s)


● Transit Blue



Regen flutet die Niederungen (Kreis 5). Klarer Dosis-Wirkungs-Schwellenwert >10mm.

Fachmessen (66.0s)

●



Fachmessen verursachen mehr systemisches Delay als Grosskonzerte.

Feiertage (-9.9s)

● Success Green



Feiertage sind die besten Tage. Die Kapazitätsgrenze liegt beim Strassenverkehr, nicht beim Fahrgast.

Diese Faktoren sind nicht-linear. Sie erfordern einen Machine-Learning-Algorithmus, der geografische und wetterbasierte Schwellenwerte isolieren kann.

The **Smoking Gun**: Kein Puffer, keine Erholung

87%

OTP (Ist)

95%

OTP (VBZ-Ziel)

71.5%

der Halte
akkumulieren Delay

71.3%

der Haltestellen haben
dwell_time = 0s

Zwei Zahlen, ein Problem. Warum bauen 71.5% der Haltestellen kontinuierlich Verspätung Weil an 71.3% der Halte exakt 0 Sekunden Standzeit (Puffer) im Fahrplan eingebaut sind. Das Zürcher System ist für dichte Takte optimiert, besitzt aber keine Stossdämpfer. Verspätung ist das Default-Ergebnis des Fahrplans.

Die Konsequenz: Der perfekte Kaskaden-Effekt



Pearson
 $r \geq 0.85$

Weil Pufferzeiten fehlen, überträgt sich die Verspätung von Halt n fast nahtlos auf Halt $n+1$. Alle 16 Linien weisen einen Korrelationskoeffizienten von $r \geq 0.85$ auf. Ein Netz, das sich selbst reparieren könnte, läge unter 0.70. Hier trägt die Endstation die akkumulierte Last der gesamten Strecke.

Das **Simulations-Paradoxon** (Der zweite Rückschlag)

Die Idee

Wir simulieren +60s dwell_time im Modell, um den Puffer-Mangel zu beheben.



Das Ergebnis

Das Modell prognostiziert **+20s MEHR** Verspätung, statt weniger.



Warum? (Confounding Variable)

Das Modell hat gelernt: Haltestellen mit 60s Puffer sind in der Realität komplexe Knotenpunkte.




Observational ML Limitierung: Feature Importance ist kein kausaler Hebel. Das Modell verstand die historischen Muster perfekt, konnte aber nicht zwischen einem komplexen Hub und einem hypothetischen Puffer unterscheiden.

Der Durchbruch: Die Physik des Netzes codieren

Die Erkenntnis

Wir wissen: Verspätung kaskadiert ($r \geq 0.85$).




Das Feature

```
# LightGBM v2 Feature Engineering
def create_features(data):
    data['prev_trip_delay'] =
        data['delay_stop_n_minus_1']
    return data

# Input to Algorithm
features = ['dwell_time', 'day_of_week',
            'prev_trip_delay']
model.fit(features, target)
```

Die Architektur



Das Modell versteht nun nicht mehr nur den Fahrplan, sondern den dynamischen Zustand des Trams vor der Ankunft.

Um das Modell zu reparieren, durften wir nicht pauschale Puffer simulieren. Wir mussten dem Modell **den Kaskadeneffekt** beibringen. LightGBM v2 nutzt den **realen Verspätungswert** des Vorgänger-Halts.

Der Quantensprung in der Vorhersage



Wenn ein Modell die Verspätung einer Tram auf 18 Sekunden genau vorhersagen kann, beweist das: Die Störung ist kein Zufall. Sie ist ein hochgradig stabiles, mathematisches Muster.

Synthese: Die Analyse diktiert das Modell


Die analytische Überraschung	Das Engineered Feature	Der Modell-Impact
Schnee betrifft Höhenlagen, nicht das Flachland	district × has_snow Interaktion	Erfasst topografische Nicht-Linearität
Abend-Abreisewellen sind kritischer als Morgenrush	hour × has_event Interaktion	Erklärt den 21h-Spike präzise
Delays kaskadieren netzweit fast perfekt	prev_trip_delay	Senkt MAE um 63%

Kein Feature wurde blind an den Algorithmus übergeben. Jede Variable in LightGBM v2 ist die **direkte mathematische Übersetzung** eines **verifizierten Analysebefunds**.

Die operative Lösung: Vom Modell zum Fahrplan

Live-Szenario

Input	Wert
Wochentag · Uhrzeit	Dienstag · 17:00
Haltestelle	Paradeplatz
Linie	11
Wetter	Leichter Regen
Vorhergesagter Delay	~52s



Das Modell ist kein Dashboard-Spielzeug.
Es generiert eine **operative Risikomatrix**.

Anstatt pauschal 0 oder 60 Sekunden
Standzeit zu verteilen, zeigt das Modell
dem Betrieb exakt, welche Haltestelle
unter welchem Kontext wie viel
dynamischen Puffer benötigt.

Datengetriebene Fahrplan-Architektur

- 1. Fahrplan-Redesign L11**
Gezielte Pufferzeiten (+10s) an 3-5 kritischen Koppelstellen einbauen, um die Kaskade ($r \geq 0.85$) zu durchbrechen.
- 2. Kontext-Schedules**
Fachmessen-Dispositionen für L11 und Schnee-Protokolle für Höhenlagen einführen. Einheitliche Puffer greifen zu kurz.
- 3. A/B-Testing**
Das Modell liefert die Diagnose, der Betrieb liefert die Dosis. Pilot-Experimente mit isolierten Puffer-Anpassungen zur Kausal-Validierung durchführen.

Vorhersagbar heisst Steuerbar

Die Verspätungen im Zürcher Tramnetz sind vorhersagbar — weil sie im Fahrplan-Design verankert sind, nicht im zufälligen Betrieb. Was 94 Millionen Datenpunkte auf 18 Sekunden genau vorhersagen können, ist kein Schicksal. Es ist Struktur. Und was Struktur hat, lässt sich neu designen.